Text Classification for Subjective Scoring Using K-Nearest Neighbors

Kittakorn Sriwanna

School of Computer and Information Technology,

Chiang Rai Rajabhat University, Thailand

The problem of old scoring system

- Manual scoring, the system require teacher to score the answer
- In a large class, high number of students, teacher take a long time to evaluate
- Unfair score the answer

Related works

- There are some works proposed the automatic scoring system for the subjective answer such as
  - Automated scoring of short-answer questions

    L. CLAUDIA and M. CC-rater, 2003
  - Automated essay scoring using the knn algorithm

    L. Bin, L. Jun, Y. Jian-Min, and Z. Qiao-Ming, 2008
- However, they can not handle with Thai language.

Related works

- The process of the work automated essay scoring using the knn algorithm

	word 1	word 2	word 3	word 4	...	score
document 1	$f_{1,1}$	$f_{1,2}$	$f_{1,3}$	$f_{1,4}$		$c_{1,n}$
document 2	$f_{2,1}$	$f_{2,2}$	$f_{2,3}$	$f_{2,4}$		$c_{2,n}$
⋮						
document m	$f_{m,1}$	$f_{m,2}$	$f_{m,3}$	$f_{m,4}$		$c_{m,n}$

word vector (TF-IDF)

word 1	word 3	word 5	word 9	score
$f_{1,1}$	$f_{1,2}$	$f_{1,3}$	$f_{1,4}$	$c_{1,n}$
$f_{2,1}$	$f_{2,2}$	$f_{2,3}$	$f_{2,4}$	$c_{2,n}$
$f_{m,1}$	$f_{m,2}$	$f_{m,3}$	$f_{m,4}$	$c_{m,n}$

Select some feature using *Term Frequency* and *Information Gain*

Predict score using knn algorithm

Predict score of new essay

Related works

- Problem of previous works
  - They cannot handle with Thai language
  - They do not consider word ordering, they evaluate the similarity using the distance of the pair of word vector

Text1 If a less than b then

Text2 If b less than a then

if	a	less	than	b
1	1	1	1	1
1	1	1	1	1

Distance(text1,text2) = 0

Objective of the proposed method

- This study proposed the automatically score the subjective answer based on words matching and word ordering
- The proposed method can handle with Thai and English language
- It consider word ordering

The proposed method

1. Split the subjective answer to the list of words/phrases using dictionary
2. apply k-nearest neighbour classifier with the proposed similarity measure

The proposed method

Example of split the subjective answer to word

เพราะคำสั่ง int x , y ; ผิดจึงทำให้ syntax error คำสั่งที่ถูกต้องคือ int x = 0, y; System.out.println("x is " + x + 1) ;

เพราะ คำสั่ง int x , y ; ผิด จึง ทำให้ syntax error คำสั่ง ที่ ถูกต้อง คือ int x = 0 , y ; System . out . println (" x is " + x + 1) ;

The proposed method

Score List of text

2	เพราะ	ไม่ได้	กำหนด	ค่า	เริ่มต้น	ของ	ตัวแปร	x								
	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า	x	+	1	มีค่า	เท่าไหร่
	error	เพราะ	ไม่มี	การ	กำหนด	ค่า	x									
	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า	x	+	1	คือ	เท่าไร
	ค่า	x	ไม่ได้	กำหนด	ค่า	ของ	ตัวแปร	จึง	ทำให้	x	ไม่ทราบ	ค่า	จึง	ไม่ได้ผล		
	เพราะ	x	ไม่ได้	กำหนด	ค่า	ระบบ	จึง	ไม่	สามารถ	แสดงผล	x	และ	y	ออกมา	ได้	
	x	คือ	sysntax	error	เพราะว่า	ไม่ได้	กำหนด	ค่า	x	ไว้	ก่อน	จึง	ทำให้เกิด	การ	error	ขึ้น

The proposed methoc

- Apply k-nn (set k=1)
- If the nearest instance has the similarity over than 0.6 then suggest the score, otherwise not suggest

0.5

Score	List of text															
2	เพราะ	ไม่ได้	กำหนด	ค่า	เริ่มต้น	ของ	ตัวแปร	x								
	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า	x				
	error	เพราะ	ไม่มี	การ	กำหนด	ค่า	x									
	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า	x	+	1	คือ	เท่าไร
	ค่า	x	ไม่ได้	กำหนด	ค่า	ของ	ตัวแปร	จึง	ทำให้	x	ไม่ทราบ	ค่า	จึง	ไม่ได้ผล		
	เพราะ	x	ไม่ได้	กำหนด	ค่า	ระบบ	จึง	ไม่	สามารถ	แสดงผล	x	และ	y	ออกมา	ได้	
	x	คือ	sysntax	error	เพราะว่า	ไม่ได้	กำหนด	ค่า	x	ไว้	ก่อน	จึง	ทำให้เกิด	การ	error	ขึ้น

The proposed method

- Apply k-nn (set k=1)
- If the nearest instance has the similarity over than 0.6 then suggest the score, otherwise not suggest.

Score	List of text															
2	เพราะ	ไม่ได้	กำหนด	ค่า	เริ่มต้น	ของ	ตัวแปร	x								
1.5	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า					
	error	เพราะ	ไม่มี	การ	กำหนด	ค่า	x									
	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า	x	+	1	คือ	เท่าไร
	ค่า	x	ไม่ได้	กำหนด	ค่า	ของ	ตัวแปร	จึง	ทำให้	x	ไม่ทราบ	ค่า	จึง	ไม่ได้ผล		
	เพราะ	x	ไม่ได้	กำหนด	ค่า	ระบบ	จึง	ไม่	สามารถ	แสดงผล	x	และ	y	ออกมา	ได้	
	x	คือ	sysntax	error	เพราะว่า	ไม่ได้	กำหนด	ค่า	x	ไว้	ก่อน	จึง	ทำให้เกิด	การ	error	ขึ้น

The proposed method

- Apply k-nn (set k=1)
- If the nearest instance has the similarity over than 0.6 then suggest the score, otherwise not suggest.

0.7

0.6

Score	List of text															
2	เพราะ	ไม่ได้	กำหนด	ค่า	เริ่มต้น	ของ	ตัวแปร	x								
1.5	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า					
	error	เพราะ	ไม่มี	การ	กำหนด	ค่า	x									
	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า	x	+	1	คือ	เท่าไร
	ค่า	x	ไม่ได้	กำหนด	ค่า	ของ	ตัวแปร	จึง	ทำให้	x	ไม่ทราบ	ค่า	จึง	ไม่ได้ผล		
	เพราะ	x	ไม่ได้	กำหนด	ค่า	ระบบ	จึง	ไม่	สามารถ	แสดงผล	x	และ	y	ออกมา	ได้	
	x	คือ	sysntax	error	เพราะว่า	ไม่ได้	กำหนด	ค่า	x	ไว้	ก่อน	จึง	ทำให้เกิด	การ	error	ขึ้น

The proposed method

- Apply k-nn (set k=1)
- If the nearest instance has the similarity over than 0.6 then suggest the score, otherwise not suggest.

Score	List of text															
2	เพราะ	ไม่ได้	กำหนด	ค่า	เริ่มต้น	ของ	ตัวแปร	x								
1.5	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า					
2	error	เพราะ	ไม่มี	การ	กำหนด	ค่า	x									
	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า	x	+	1	คือ	เท่าไร
	ค่า	x	ไม่ได้	กำหนด	ค่า	ของ	ตัวแปร	จึง	ทำให้	x	ไม่ทราบ	ค่า	จึง	ไม่ได้ผล		
	เพราะ	x	ไม่ได้	กำหนด	ค่า	ระบบ	จึง	ไม่	สามารถ	แสดงผล	x	และ	y	ออกมา	ได้	
	x	คือ	sysntax	error	เพราะว่า	ไม่ได้	กำหนด	ค่า	x	ไว้	ก่อน	จึง	ทำให้เกิด	การ	error	ขึ้น

The proposed method

- Apply k-nn (set k=1)
- If the nearest instance has the similarity over than 0.6 then suggest the score, otherwise not suggest.

Score	List of text															
2	เพราะ	ไม่ได้	กำหนด	ค่า	เริ่มต้น	ของ	ตัวแปร	x								
1.5	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า					
2	error	เพราะ	ไม่มี	การ	กำหนด	ค่า	x									
	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า	x	+	1	คือ	เท่าไร
	ค่า	x	ไม่ได้	กำหนด	ค่า	ของ	ตัวแปร	จึง	ทำให้	x	ไม่ทราบ	ค่า	จึง	ไม่ได้ผล		
	เพราะ	x	ไม่ได้	กำหนด	ค่า	ระบบ	จึง	ไม่	สามารถ	แสดงผล	x	และ	y	ออกมา	ได้	
	x	คือ	sysntax	error	เพราะว่า	ไม่ได้	กำหนด	ค่า	x	ไว้	ก่อน	จึง	ทำให้เกิด	การ	error	ขึ้น

0.5

0.7

0.4

The proposed method

- Apply k-nn (set k=1)
- If the nearest instance has the similarity over than 0.6 then suggest the score, otherwise not suggest it

Score	List of text															
2	เพราะ	ไม่ได้	กำหนด	ค่า	เริ่มต้น	ของ	ตัวแปร	x								
1.5	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า					
2	error	เพราะ	ไม่มี	การ	กำหนด	ค่า	x									
1.5	เพราะ	เรา	ไม่ได้	กำหนด	ค่า	x	จริง	ไม่	แสดง	ผลได้	ว่า	x	+	1	คือ	เท่าไร
	ค่า	x	ไม่ได้	กำหนด	ค่า	ของ	ตัวแปร	จึง	ทำให้	x	ไม่ทราบ	ค่า	จึง	ไม่ได้ผล		
	เพราะ	x	ไม่ได้	กำหนด	ค่า	ระบบ	จึง	ไม่	สามารถ	แสดงผล	x	และ	y	ออกมา	ได้	
	x	คือ	sysntax	error	เพราะว่า	ไม่ได้	กำหนด	ค่า	x	ไว้	ก่อน	จึง	ทำให้เกิด	การ	error	ขึ้น

The Proposed similarity algorithm

Input: text answer u, and text answer v
Output: the similarity score, $sim(u, v)$

```
generate a list of word u, list_u and list of word v, list_v
let length_u and length_v are the lengths of list_u and list_v, respectively
for all word u_i, where u_i ∈ list_u do
    for all word v_j, where v_j ∈ list_v do
        if u_i = v_j then
            calculate matching score u_i and v_j,
            score = m(u_i, v_j),
            m(u_i, v_j) = 1 − |u_i/length_u − v_j/length_v|
            keep the highest score value
        end if
    end for
end for
let length_max is the maximum of lenght_u and length_v
let sum(score) is the summation of all the matching score
sim(u, v) = sum(score)/length_max
```

The propose similarity lies between 0 and 1

If array of two words have the same wording and ordering, the similarity is high

The proposed method

- The efficiency of the proposed method depend on the number of the answer that already been score
- Because the nearest instance can be find using the subjective answers that already been score, at the beginning, the scoring system may not suggest the good result
- After there are many subjective answers that already been score, the proposed scoring system will increase the efficiency

Evaluation Methodology

- Test with 6 real subjective answer, random separate to the training set 80% and testing set 20%.
- Investigated the original 3 classifiers of: C4.5, SVM, KNN
- Measure with predictive accuracy.

Evaluation Methodology

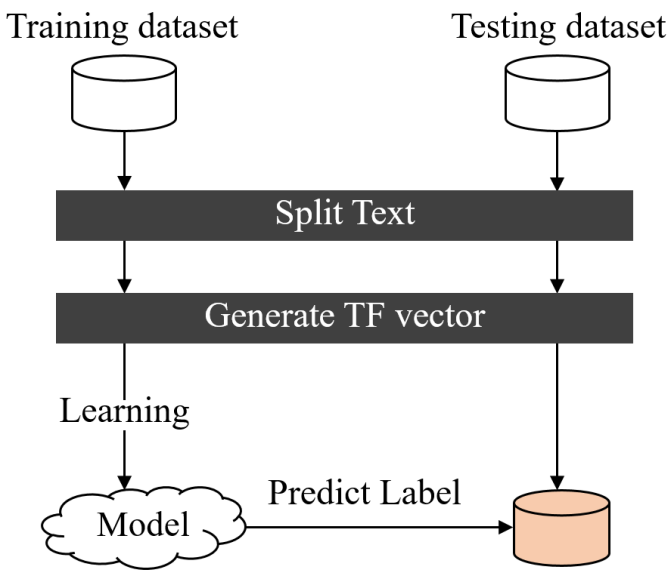

The process of score prediction for C4.5, SVM, and original KNN

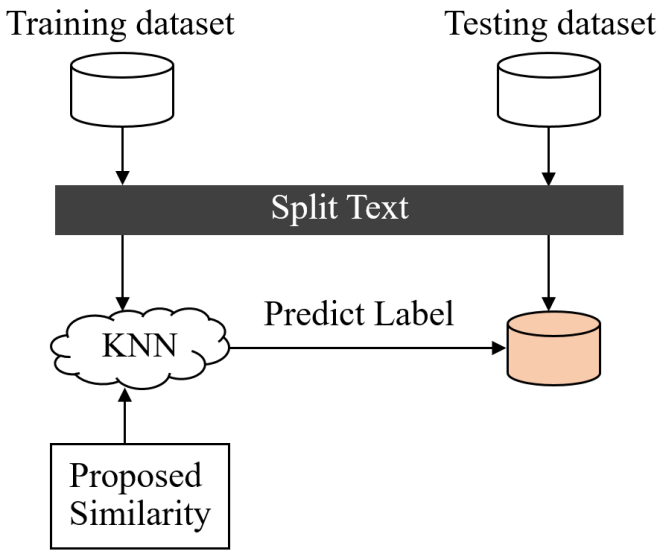

The process of the proposed method

Result of the proposed algorithm

Predictive accuracy result

	Dataset	C4.5	SVM	KNN	$KNN_{proposed}$
List of words	Answer1	**100**	91.67	**100**	**100**
List of code	Answer2	53.85	38.46	53.85	**84.61**
List of code	Answer3	46.15	38.46	61.54	**76.92**
List of code	Answer4	**83.33**	58.33	**83.33**	**83.33**
List of T/F	Answer5	46.15	46.15	46.15	**76.92**
List of code	Answer6	66.67	58.33	75.00	**91.67**
	Average	66.12	55.68	70.69	**86.44**

Conclusion

This research proposed text classification for subjective scoring using k-nearest neighbors algorithm with the proposed similarity algorithm

The proposed similarity algorithm is based on word matching and word ordering

It can be coupled with Thai and English languages