

แอปพลิเคชันบนอุปกรณ์พกพาสำหรับการวินิจฉัยโรคผิวหนัง ด้วยเทคโนโลยีการเรียนรู้เชิงลึก

Deep Learning-Based Mobile App for Skin Disease Identification

"กรุณาย้ายใส่ชื่อผู้แต่ง"



บทคัดย่อ

งานวิจัยนี้นำเสนอการพัฒนาแอปพลิเคชันบนสมาร์ทโฟนเพื่อการคัดกรองโรคผิวหนังเบื้องต้นจากภาพถ่าย โดยประยุกต์ใช้เทคโนโลยีการเรียนรู้เชิงลึกผ่านสถาปัตยกรรมเครือข่ายประสาทเทียมแบบคอนโวลูชัน (CNN) ได้แก่ EfficientNetB0 และ MobileNetV3Small ซึ่งถูกพัฒนาเป็นแบบจำลองแบบรวม (Ensemble Model) โดยใช้ชุดข้อมูล HAM10000 ในการฝึกฝนและทดสอบแบบจำลอง โดยวัดผลผ่านตัวชี้วัดความถูกต้อง (Accuracy), ความแม่นยำ (Precision), ความไว (Sensitivity), คะแนน F1 (F1-score) ผลการทดลองพบว่าแบบจำลองแบบรวมมีความถูกต้องสูงถึงร้อยละ 85.70 ซึ่งมีประสิทธิภาพเหมาะสมสำหรับการใช้งานจริงบนระบบปฏิบัติการแอนดรอยด์ (Android) ผ่านคลังโปรแกรม TensorFlow Lite ทั้งนี้ ระบบถูกออกแบบให้เป็นเครื่องมือคัดกรองเบื้องต้นเท่านั้น และไม่สามารถทดแทนการวินิจฉัยโดยแพทย์ผู้เชี่ยวชาญได้

คำสำคัญ -- การคัดกรองโรคผิวหนัง, การเรียนรู้เชิงลึก, เครือข่ายประสาทเทียมแบบคอนโวลูชัน, แบบจำลองแบบรวม, สมาร์ทโฟน

ABSTRACT

This research presents the development of a smartphone-based application for preliminary skin disease screening. The system utilizes deep learning technology based on Convolutional Neural Network (CNN) architectures, specifically EfficientNetB0 and

MobileNetV3Small, which are integrated into an Ensemble Model. The HAM10000 dataset was employed for model training and evaluation. Performance was assessed using Accuracy, Precision, Sensitivity and F1-score. Experimental results demonstrated that the Ensemble Model achieved an accuracy of 85.70%, indicating suitable efficiency for real-world deployment on the Android operating system via the TensorFlow Lite library. However, the system is designed solely as a preliminary screening tool and is not intended to replace diagnosis by medical specialists.

Keywords -- Skin Disease Screening, Deep Learning, Convolutional Neural Networks, Ensemble Model, Smartphone

1. บทนำ

โรคผิวหนังเป็นปัญหาสาธารณสุขสำคัญระดับโลกที่ส่งผลกระทบต่อคุณภาพชีวิตของประชาชนจำนวนมาก [1], [2] โดยเฉพาะในสังคมผู้สูงอายุที่ผิวหนังเสื่อมสภาพตามวัยทำให้เกิดโรคได้ง่าย [3], [4] ปัญหานี้ยิ่งรุนแรงขึ้นจากการขาดแคลนแพทย์ผู้เชี่ยวชาญด้านผิวหนัง (Dermatology) และการกระจายตัวของบุคลากรที่ไม่ทั่วถึง ดังจะเห็นได้จากสถิติในสหรัฐอเมริกาและประเทศไทยที่แพทย์ส่วนใหญ่มักกระจุกตัวอยู่ในเขตเมือง [5],

[6] ความล่าช้านี้ส่งผลโดยตรงต่อกระบวนการวินิจฉัย ซึ่งเป็นปัจจัยชี้ขาดต่อผลการรักษาและโอกาสรอดชีวิตของผู้ป่วย โดยเฉพาะในกลุ่มโรคมะเร็งผิวหนังชนิดเมลาโนมา [7], [8]

ปัจจุบันเทคโนโลยีปัญญาประดิษฐ์ (AI) โดยเฉพาะการเรียนรู้เชิงลึกได้เข้ามามีบทบาทสำคัญในการเพิ่มขีดความสามารถการวิเคราะห์ภาพทางการแพทย์ [9] อย่างไรก็ตาม การพัฒนาโครงข่ายประมวลผลที่มีขนาดเล็ก ใช้ทรัพยากรน้อย และสามารถทำงานได้อย่างมีประสิทธิภาพบนสมาร์ตโฟน ยังคงเป็นประเด็นสำคัญที่ต้องได้รับการแก้ไข [10] งานวิจัยนี้จึงมีวัตถุประสงค์เพื่อพัฒนาแอปพลิเคชันบนสมาร์ตโฟนสำหรับคัดกรองโรคผิวหนังเบื้องต้นจากภาพถ่าย โดยมุ่งเน้นการออกแบบและสร้างแบบจำลองการเรียนรู้เชิงลึกด้วยสถาปัตยกรรมเครือข่ายประสาทเทียมแบบคอนโวลูชัน (CNN) ที่ทันสมัย ให้สามารถจำแนกรอยโรคผิวหนังได้อย่างมีประสิทธิภาพ

งานวิจัยนี้เลือกใช้สถาปัตยกรรมแบบจำลองขนาดเล็ก ได้แก่ MobileNetV3Small [11] และ EfficientNetB0 [12] มาพัฒนาเป็นแบบจำลองแบบรวม (Ensemble Model) โดยมีเหตุผลสำคัญ คือ สถาปัตยกรรมทั้งสองถูกออกแบบมาเพื่อการประมวลผลบนสมาร์ตโฟนโดยเฉพาะ ซึ่งมีจุดเด่นด้านการใช้พารามิเตอร์และทรัพยากรคำนวณที่ต่ำ แต่ยังคงความแม่นยำในการจำแนกภาพไว้ในระดับสูง จึงมีความเหมาะสมอย่างยิ่งสำหรับการประมวลผลบนสมาร์ตโฟนที่มีข้อจำกัดด้านฮาร์ดแวร์

งานวิจัยนี้กำหนดขอบเขตการศึกษาโดยมุ่งเน้นการวินิจฉัยรอยโรคผิวหนัง 7 กลุ่มโรค อ้างอิงตามชุดข้อมูล HAM10000 และการพัฒนาแอปพลิเคชัน จะเน้นระบบที่สามารถประมวลผลได้เบ็ดเสร็จบนอุปกรณ์ (On-device Processing) โดยไม่ต้องพึ่งพาการเชื่อมต่ออินเทอร์เน็ตตลอดเวลา โดยมีการกำหนดตัวชี้วัดประสิทธิภาพที่สำคัญ ดังแสดงรายละเอียดในตารางที่ 1

ตาราง 1 ตัวชี้วัดประสิทธิภาพที่ใช้ในการประเมินผลแบบจำลอง

ตัวชี้วัด	รายละเอียด
ความถูกต้อง (Accuracy)	สัดส่วนของจำนวนข้อมูลที่ทำนายถูกต้องทั้งหมดเทียบกับจำนวนข้อมูลทั้งหมด ใช้บ่งบอกประสิทธิภาพภาพรวมของแบบจำลองในการจำแนกโรคทุกประเภท
ความแม่นยำ (Precision)	สัดส่วนของข้อมูลที่แบบจำลองทำนายว่าเป็นโรคและเป็นโรคนั้นจริง มีความสำคัญ

	ในการช่วยลดความกังวลของผู้ใช้งานที่เกิดจากการแจ้งเตือนผิดพลาด (ผลบวกลวง)
ความไว (Sensitivity)	ความสามารถของแบบจำลองในการตรวจพบผู้ที่ เป็นโรคจริงได้ครบถ้วน มีความสำคัญสูงสุดสำหรับเครื่องมือคัดกรองเพื่อป้องกันไม่ให้ผู้ป่วยหลุดรอดการรักษา (ผลลบลวง)
คะแนน F1 (F1-score)	ค่าเฉลี่ยฮาร์โมนิกระหว่างความแม่นยำและความไว ใช้ประเมินประสิทธิภาพของแบบจำลองให้มีความสมดุล โดยเฉพาะในกรณีที่ชุดข้อมูลมีการกระจายตัวของโรคแต่ละประเภทไม่เท่ากัน
ขนาดของแบบจำลอง	ขนาดพื้นที่จัดเก็บของไฟล์แบบจำลอง ภายหลังการแปลงสภาพเพื่อใช้งานบนสมาร์ตโฟน (TensorFlow Lite) ซึ่งส่งผลต่อขนาดของแอปพลิเคชัน

นอกเหนือจากตัวชี้วัดข้างต้น ยังมีการวิเคราะห์ผลผ่านตารางความสับสน (Confusion Matrix) เพื่อตรวจสอบการกระจายตัวของความผิดพลาดในแต่ละคลาสโรค ท้ายที่สุด งานวิจัยนี้มุ่งหวังให้ผลลัพธ์ที่ได้เป็นเครื่องมือสนับสนุนการตัดสินใจที่ช่วยขยายโอกาสการเข้าถึงบริการสาธารณสุขและลดภาระงานของบุคลากรทางการแพทย์ สอดคล้องกับเป้าหมายการพัฒนาที่ยั่งยืน (SDGs) ด้านการมีสุขภาพและความเป็นอยู่ที่ดีสำหรับทุกคน [13]

2. ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

บทนี้กล่าวถึงหลักการ ทฤษฎีพื้นฐาน และเทคนิคที่เกี่ยวข้องกับการพัฒนาแบบจำลองโครงข่ายประสาทเทียมเพื่อจำแนกรอยโรคผิวหนัง โดยครอบคลุมตั้งแต่สถาปัตยกรรมหลักของแบบจำลอง ไปจนถึงวิธีการเพิ่มประสิทธิภาพการทำงาน

2.1 เครือข่ายประสาทเทียมแบบคอนโวลูชัน

2.1.1 การเรียนรู้เชิงลึก

การเรียนรู้เชิงลึก (Deep Learning) เป็นสาขาย่อยของปัญญาประดิษฐ์ (AI) ที่จำลองการทำงานของสมองมนุษย์ผ่านโครงข่ายประสาทเทียมหลายชั้น (Deep Neural Networks)

ซึ่งมีความสามารถโดดเด่นในการเรียนรู้และสกัดคุณลักษณะ (Features) ที่ซับซ้อนจากข้อมูลดิบโดยอัตโนมัติ

2.1.2 การทำงานพื้นฐานของ CNN

เครือข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Networks) [15] เป็นสถาปัตยกรรมที่มีประสิทธิภาพสูงที่สุดสำหรับการวิเคราะห์ภาพ CNN มีโครงสร้างแบบลำดับชั้นที่ช่วยให้สามารถเรียนรู้คุณลักษณะของภาพโดยอัตโนมัติ ซึ่งมีขั้นตอนการทำงานหลัก ดังนี้

(1) ชั้นคอนโวลูชัน

ทำหน้าที่สกัดคุณลักษณะสำคัญ เช่น ขอบ, เส้น, หรือพื้นผิว โดยใช้ตัวกรองเลื่อนคำนวณไปทั่วทั้งภาพ

(2) ชั้นพูลลิง

ทำหน้าที่ลดขนาดมิติของข้อมูล (Down-sampling) เพื่อลดปริมาณการคำนวณ ลดจำนวนพารามิเตอร์ และป้องกันการเรียนรู้เกิน (Overfitting)

(3) ชั้นเชื่อมต่อสมบูรณ์

ทำหน้าที่ประมวลผลคุณลักษณะที่สกัดได้จากชั้นก่อนหน้าทั้งหมดเพื่อทำการจำแนกประเภทในขั้นสุดท้าย

2.1.3 ฟังก์ชันซอฟต์แวร์แมกซ์

ในขั้นสุดท้ายของโครงข่ายประสาทเทียม จะใช้ฟังก์ชันซอฟต์แวร์แมกซ์ (Softmax Function) เพื่อแปลงค่าผลลัพธ์ดิบ (Logits) ให้อยู่ในรูปของความน่าจะเป็น โดยที่ผลรวมของความน่าจะเป็นทุกคลาสจะมีค่าเท่ากับ 1 ซึ่งคำนวณได้ดังสมการ

$$P_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} \quad (1)$$

โดยที่

- P_j คือ ความน่าจะเป็นของคลาส j ที่โมเดลทำนาย
- Z_j คือ เวกเตอร์ผลลัพธ์จากชั้นก่อนหน้า (Logits)
- K คือ จำนวนคลาสทั้งหมด (ในงานวิจัยนี้ $K=7$)
- e คือ ค่าคงที่ของออยเลอร์

ผลลัพธ์จากฟังก์ชันนี้จะถูกนำไปเปรียบเทียบกับเพื่อระบุว่าภาพนำเข้ามีความน่าจะเป็นที่จะเป็นโรคผิวหนังชนิดใดมากที่สุด

2.2 สถาปัตยกรรมแบบจำลองที่เลือกใช้

เพื่อให้สอดคล้องกับวัตถุประสงค์ในการพัฒนาแอปพลิเคชันบนสมาร์ทโฟน ซึ่งมีข้อจำกัดด้านทรัพยากร งานวิจัยนี้จึงคัดเลือกสถาปัตยกรรมเครือข่ายประสาทเทียมขนาดเล็กที่มีความสมดุลระหว่างความเร็วและความถูกต้อง จำนวน 2 สถาปัตยกรรม

2.2.1 MobileNetV3

MobileNetV3 [11] ถูกพัฒนาโดย Google ภายใต้หลักการออกแบบ Mobile-First ที่เน้นประสิทธิภาพสูงบนอุปกรณ์พกพาเป็นสำคัญ สถาปัตยกรรมนี้มีการปรับปรุงประสิทธิภาพด้วยเทคนิคสำคัญ ได้แก่

(1) การค้นหาโครงสร้างอัตโนมัติ

ใช้เทคนิค MnasNet เพื่อค้นหาโครงสร้างที่ให้จุดสมดุลที่สุดระหว่างความแม่นยำและความหน่วงเวลา

(2) Squeeze-and-Excitation (SE) Block

โมดูลพิเศษที่ช่วยให้เครือข่ายสามารถเรียนรู้ที่จะให้ความสำคัญกับช่องสัญญาณที่มีข้อมูลจำเพาะมากกว่า

(3) ฟังก์ชันกระตุ้นแบบ Hard-Swish

ฟังก์ชันกระตุ้นรูปแบบใหม่ที่ช่วยลดความซับซ้อนในการคำนวณ ทำให้ประมวลผลได้รวดเร็วยิ่งขึ้นบนหน่วยประมวลผลของอุปกรณ์พกพา

งานวิจัยนี้เลือกใช้รุ่น MobileNetV3Small ซึ่งมีขนาดเล็กและความเร็วในการประมวลผลสูงที่สุดในตระกูล MobileNetV3

2.2.2 EfficientNet

EfficientNet [12] เสนอแนวคิด Compound Scaling Method หรือการปรับขยายขนาดโมเดลแบบผสมผสาน ซึ่งปรับสมดุลทั้ง 3 ปัจจัย โดยใช้ค่าสัมประสิทธิ์ที่เหมาะสม ได้แก่

- (1) ความกว้าง (Width): จำนวนช่องสัญญาณในแต่ละชั้น
- (2) ความลึก (Depth): จำนวนชั้น (Layers) ของเครือข่าย
- (3) ความละเอียด (Resolution): ขนาดของภาพนำเข้า

การขยายแบบผสมผสานนี้ทำให้ได้โมเดลที่มีประสิทธิภาพสูงกว่าการปรับขยายเพียงมิติเดียว งานวิจัยนี้ใช้ EfficientNetB0 ซึ่งเป็นรุ่นพื้นฐานที่ได้จากการค้นหาโครงสร้างอัตโนมัติ มีจุดเด่นคือขนาดเล็กแต่ให้ความถูกต้องเทียบเท่าโมเดลที่มีขนาดใหญ่กว่า

2.3 การจัดการข้อมูลและการเพิ่มประสิทธิภาพแบบจำลอง

2.3.1 การสุ่มเพิ่มข้อมูล

เนื่องจากชุดข้อมูล HAM10000 มีความแตกต่างของจำนวนภาพในแต่ละคลาสสูง ซึ่งอาจส่งผลให้แบบจำลองเกิดความลำเอียง (Bias) งานวิจัยนี้จึงแก้ปัญหาด้วยวิธีการสุ่มเพิ่มข้อมูล (Random Oversampling) โดยทำการสุ่มคัดลอกภาพในคลาสที่มีจำนวนน้อย (Minority Class) ซ้ำ ๆ จนกระทั่งมีจำนวนเท่ากับคลาสที่มีจำนวนมากที่สุด วิธีนี้ช่วยให้แบบจำลองสามารถเรียนรู้คุณลักษณะของโรคทุกประเภทได้อย่างทั่วถึง

2.3.2 การเรียนรู้แบบรวม

เป็นเทคนิคที่นำผลลัพธ์จากแบบจำลองหลายตัวมารวมกัน ประมวลผลเพื่อเพิ่มความแม่นยำและความเสถียร งานวิจัยนี้ เลือกใช้การลงคะแนนแบบความน่าจะเป็น (Soft Voting) หรือ การหาค่าเฉลี่ยความน่าจะเป็น (Average Probability) จากทั้ง MobileNetV3Small และ EfficientNetB0 ซึ่งช่วยลดความแปรปรวน (Variance) ของการทำนาย โดยค่าความน่าจะเป็นรวมของคลาสสุดท้าย ($P_{Ensemble}$) สำหรับแต่ละคลาสโรค (c) สามารถคำนวณได้จากค่าเฉลี่ยของความน่าจะเป็นที่ได้จากแบบจำลองทั้งหมดจำนวน N ตัว ดังสมการต่อไปนี้

$$P_{Ensemble}(c) = \frac{1}{N} \sum_{i=1}^N P_i(c) \quad (2)$$

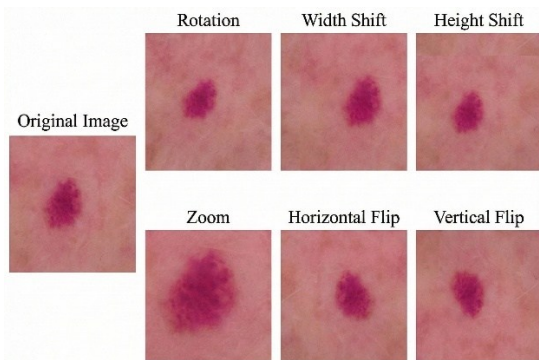
โดยที่

- $P_{Ensemble}(c)$ คือ ค่าความน่าจะเป็นรวมของ (c)
- N คือ จำนวนแบบจำลองทั้งหมดที่นำมารวมกัน
- $P_i(c)$ คือ ค่าความน่าจะเป็นของ (c) ที่ทำนายโดยแบบจำลองลำดับที่ i

ซึ่งในงานวิจัยนี้ $P_1(c)$ และ $P_2(c)$ แทนค่าความน่าจะเป็นจาก MobileNetV3Small และ EfficientNetB0 ตามลำดับในขั้นตอนสุดท้าย ระบบจะตัดสินใจเลือกคลาสที่มีค่า $P_{Ensemble}$ สูงที่สุดเป็นผลลัพธ์การวินิจฉัย

2.3.3 การเพิ่มข้อมูลระหว่างการทดสอบ

Test Time Augmentation (TTA) เป็นเทคนิคการเพิ่มประสิทธิภาพในขั้นตอนการทดสอบ โดยการสร้างภาพจำลองเพิ่มเติมจากภาพนำเข้าเดิมด้วยการปรับแต่ง ดังแสดงในภาพที่ 1 แล้วนำภาพทั้งหมดไปผ่านแบบจำลองเพื่อทำนายผล จากนั้นจึงนำผลลัพธ์ทั้งหมดมาหาค่าเฉลี่ย วิธีการนี้ช่วยเพิ่มความทนทาน (Robustness) ของระบบต่อมุมมองที่หลากหลายยิ่งขึ้น



ภาพ 1 ตัวอย่างกระบวนการสร้างภาพจำลองเพิ่มเติมจากภาพนำเข้าเดิมด้วยการปรับแต่งสำหรับเทคนิคการเพิ่มข้อมูล

2.3.4 การลดความละเอียดของแบบจำลอง

การลดความละเอียดของแบบจำลอง (Quantization) เป็นเทคนิคการลดความละเอียดของตัวเลขที่ใช้ในการเก็บค่าน้ำหนักและค่ากระตุ้น (Activations) ของแบบจำลอง (เช่น แปลงจาก Float32 เป็น Int8) กระบวนการนี้ช่วยลดขนาดไฟล์แบบจำลองลงได้อย่างมีนัยสำคัญ และเพิ่มความเร็วในการประมวลผล ดังแสดงในตารางที่ 2 ซึ่งเป็นขั้นตอนสำคัญที่ทำให้สามารถใช้งานแบบจำลองบนสมาร์ตโฟนทั่วไปได้

ตาราง 2 เปรียบเทียบคุณสมบัติระหว่างโมเดลแบบความละเอียดสูง (Float32) และแบบลดความละเอียด (Int8)

คุณสมบัติ	Float32 (ดั้งเดิม)	Int8 (Quantization)
ความละเอียดข้อมูล	32-bit Floating Point	8-bit Integer
ขนาดไฟล์	ใหญ่ (100%)	เล็กมาก (25%)
ความแม่นยำ	สูงสุด	ลดลงเล็กน้อย
ความเร็วประมวลผล	ปานกลาง	เร็วมาก

2.3.5 เทคนิคการถ่ายโอนการเรียนรู้

เทคนิคการถ่ายโอนการเรียนรู้ (Transfer Learning) เป็นกระบวนการที่ใช้แบบจำลองโครงข่ายประสาทเทียมที่ได้รับการฝึกฝนด้วยชุดข้อมูลขนาดใหญ่มาก่อนแล้ว (Pre-trained Model) เช่น บน ImageNet) มาเป็นจุดเริ่มต้นในการฝึกฝนสำหรับงานวิจัยปัจจุบัน วิธีนี้ช่วยให้สามารถลดเวลาในการฝึกฝนได้อย่างมาก และช่วยให้แบบจำลองมีความแม่นยำสูงขึ้น แม้จะใช้ชุดข้อมูลสำหรับฝึกฝนที่มีขนาดเล็กกว่าก็ตาม

2.4 งานวิจัยที่เกี่ยวข้อง

2.4.1 การจำแนกโรคผิวหนังด้วย CNN

งานวิจัยส่วนใหญ่มุ่งเน้นเพิ่มความแม่นยำในการวินิจฉัยโรคผิวหนังโดยใช้ชุดข้อมูล HAM10000 ร่วมกับ CNN ขนาดใหญ่ เช่น ResNet, DenseNet และ InceptionV3 Shahin และคณะ [16] ใช้ ResNet50 และ InceptionV3 ในการจำแนก 7 ชนิดของโรคผิวหนัง และพบว่าแบบจำลองที่มีความลึกสูงให้ความแม่นยำสูงถึงร้อยละ 89.9

อย่างไรก็ตาม Zhang และคณะ [17] ชี้ให้เห็นถึงข้อจำกัดสำคัญว่า แบบจำลองกลุ่ม DenseNet แม้จะแม่นยำสูง แต่ต้อง

ใช้ทรัพยากรในการคำนวณมหาศาล และมีขนาดไฟล์ที่ใหญ่ ซึ่งเป็นอุปสรรคต่อการนำไปใช้งานบนอุปกรณ์ที่มีทรัพยากรจำกัด

2.4.2 การประยุกต์ใช้โมเดลขนาดเล็ก

เพื่อตอบโจทย์การใช้งานบนสมาร์ตโฟน งานวิจัยจึงเริ่มให้ความสำคัญกับสถาปัตยกรรมที่ออกแบบมาเพื่อประสิทธิภาพและความเร็ว โดย Chaturvedi และคณะ [18] ได้ทดสอบเปรียบเทียบประสิทธิภาพของ MobileNet กับโมเดลแบบดั้งเดิม ผลการทดลองยืนยันว่า MobileNet สามารถลดเวลาในการอนุมานลงได้อย่างมีนัยสำคัญ โดยความแม่นยำลดลงเพียงเล็กน้อยเท่านั้น

นอกจากนี้ Atwary และคณะ [19] นำ EfficientNetB0 มาประยุกต์ใช้ โดยอาศัยหลักการปรับขยายแบบผสมผสาน ซึ่งพิสูจน์ได้ว่าเหมาะสมกับการใช้งานทางการแพทย์บนสมาร์ตโฟน เนื่องจากให้ความสมดุลที่ีระหว่างจำนวนพารามิเตอร์และความถูกต้องของผลลัพธ์

2.4.3 การเพิ่มประสิทธิภาพด้วยการเรียนรู้แบบรวม

เพื่อแก้ไขปัญหาความแปรปรวนในการทำนายและเพิ่มความน่าเชื่อถือของระบบ งานวิจัยหลายชิ้นได้การเรียนรู้แบบรวมมาประยุกต์ใช้ โดย Harangi [20] เสนอวิธีการรวมผลลัพธ์จากแบบจำลอง CNN 4 สถาปัตยกรรม โดยใช้การลงคะแนนแบบถ่วงน้ำหนัก และแสดงให้เห็นว่าการรวมโมเดลช่วยเพิ่มความแม่นยำรวมได้สูงกว่าการใช้โมเดลเดี่ยว

สอดคล้องกับงานวิจัยของ Mahbod และคณะ [21] ที่ใช้การลงคะแนนแบบความน่าจะเป็น ในการรวมค่าความน่าจะเป็นจากหลายโมเดล ซึ่งไม่เพียงแต่ช่วยลดอัตราการผลิตผลลบลงในคลาสที่มีข้อมูลน้อย แต่ยังช่วยเพิ่มความทนทานของระบบต่อภาพที่มีสัญญาณรบกวนได้อีกด้วย


3. วิธีการดำเนินงาน

งานวิจัยนี้มีกระบวนการดำเนินงานหลัก 5 ขั้นตอน ได้แก่ การเตรียมชุดข้อมูล การพัฒนาสถาปัตยกรรมแบบจำลอง การกำหนดค่าสำหรับการฝึกสอน การปรับปรุงประสิทธิภาพเพื่อการใช้งานจริง และการพัฒนาแอปพลิเคชัน

3.1 การเตรียมชุดข้อมูล

การศึกษานี้ใช้ชุดข้อมูลมาตรฐาน HAM10000 [14] ซึ่งประกอบด้วยภาพถ่ายรอยโรคผิวหนังจำนวน 10,015 ภาพ จำแนกเป็น 7 กลุ่ม ดังแสดงตัวอย่างในภาพที่ 2 ได้แก่

- (1) Actinic Keratoses (akiec)
ผื่นผิวหนังอักเสบจากแสงแดด เป็นรอยโรคระยะก่อนมะเร็ง ลักษณะเป็นปื้นแดงมีขุยขาวหรือเหลือง
- (2) Basal Cell Carcinoma (bcc)
มะเร็งผิวหนังชนิดเบซอลเซลล์ เป็นมะเร็งที่พบบ่อย ลักษณะเป็นตุ่มนูนมีนวลคล้ายไข่มุก
- (3) Benign Keratosis-like Lesions (bkl)
รอยโรคคล้ายกระเนื้อ เป็นรอยโรคไม่ใช่มะเร็ง ลักษณะคล้ายก้อนแปะติดผิว
- (4) Dermatofibroma (df)
เนื้องอกเส้นใยผิวหนัง เป็นเนื้องอกไม่ร้ายแรง ลักษณะเป็นตุ่มนูนแข็ง มีรอยบุ๋มเมื่อบีบผิว
- (5) Melanoma (mel)
มะเร็งผิวหนังชนิดเมลาโนมา เป็นมะเร็งรุนแรงมาก มีลักษณะตามกฎ ABCDE
- (6) Melanocytic Nevi (nv)
ไฝปกติ เกิดจากการรวมกลุ่มของเซลล์เม็ดสี มีสีสม่ำเสมอและขอบเขตเรียบชัดเจน
- (7) Vascular Lesions (vasc)
รอยโรคของหลอดเลือด เป็นรอยโรคจากหลอดเลือดฝอยขยายตัว ลักษณะเป็นตุ่มนูนสีแดงสดหรือม่วงเข้ม



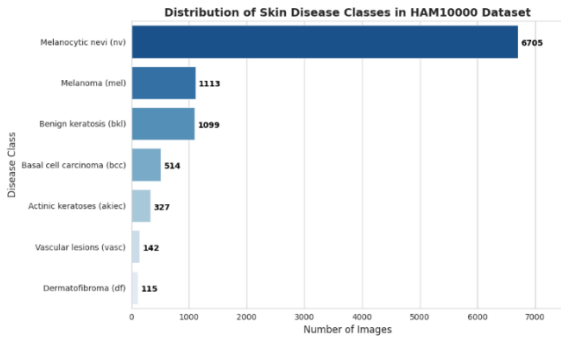
ภาพ 2 ตัวอย่างรอยโรคผิวหนัง 7 ประเภทจากชุดข้อมูล HAM10000

3.1.1 การแบ่งชุดข้อมูล

การแบ่งข้อมูลจะใช้วิธีสุ่มแบบแบ่งชั้นภูมิ เพื่อให้สัดส่วนของโรคทั้ง 7 คลาสเท่ากันในทุกชุดข้อมูล ได้แก่ ชุดข้อมูลฝึกสอนจำนวน 7,010 ภาพ, ชุดข้อมูลตรวจสอบจำนวน 1,502 ภาพ และชุดข้อมูลทดสอบจำนวน 1,503 ภาพ

3.1.2 การแก้ปัญหาความไม่สมดุลของข้อมูล

เนื่องจากชุดข้อมูลมีความไม่สมดุลของจำนวนภาพในแต่ละกลุ่มโรคอย่างมีนัยสำคัญ ดังแสดงในภาพที่ 3



ภาพ 3 แผนภูมิแสดงจำนวนภาพในแต่ละกลุ่มโรค


จึงต้องแก้ปัญหาด้วยการสุ่มเพิ่มข้อมูล โดยการหมุนภาพ, การพลิกภาพ และการขยายภาพ ทำให้ชุดข้อมูลฝึกสอนมีจำนวนเพิ่มขึ้นจากเดิม 7,010 ภาพ เป็น 32,851 ภาพ โดยแสดงรายละเอียดดังตารางที่ 3

ตาราง 3 รายละเอียดการกระจายตัวของภาพแยกตามกลุ่มโรค

กลุ่มโรค	ชุดข้อมูล สอน (ก่อน)	ชุดข้อมูล สอน (หลัง)	ชุดข้อมูล ตรวจสอบ	ชุดข้อมูล ทดสอบ
nv	4,694	4,694	1,006	1,005
mel	779	4,694	167	167
bkl	770	4,694	164	165
bcc	360	4,694	77	77
akiec	229	4,694	49	49
vasc	99	4,694	22	21
df	79	4,694	17	19
รวม	7,010	32,851	1,502	1,503

3.1.3 การประมวลผลข้อมูลขั้นต้น

กระบวนการประมวลผลข้อมูลขั้นต้นมีวัตถุประสงค์เพื่อเตรียมความพร้อมของภาพถ่ายรอยโรคผิวหนังก่อนนำเข้าสู่การฝึกสอนแบบจำลองเครือข่ายประสาทเทียมแบบคอนโวลูชัน โดยดำเนินการตามลำดับขั้นตอน ดังแสดงในภาพที่ 4



ภาพ 4 แผนภาพขั้นตอนกระบวนการประมวลผลข้อมูลขั้นต้น

ซึ่งกระบวนการประกอบด้วย 3 ขั้นตอน ดังนี้

- 1) ปรับขนาดภาพเป็น 224 x 224 พิกเซล ตามข้อกำหนด

- 2) เพิ่มข้อมูลโดยหมุน พลิก และขยายภาพ เพื่อเสริมความหลากหลายมุมมอง
- 3) ปรับค่าความเข้มพิกเซลให้อยู่ในช่วง 0 - 1 เพื่อความเหมาะสมในการคำนวณแบบจำลอง

3.2 สถาปัตยกรรมของแบบจำลอง

งานวิจัยนี้ใช้เทคนิคการเรียนรู้แบบ Transfer Learning บนสถาปัตยกรรม MobileNetV3Small และ EfficientNetB0 ที่ผ่านการฝึกฝนล่วงหน้าด้วยชุดข้อมูล ImageNet โดยมีขั้นตอนการปรับแต่งโครงสร้างดังนี้

3.2.1 การกำหนดโครงสร้างชั้นจำแนกผลลัพธ์

มีการตัดเลเยอร์สำหรับการจำแนกผลลัพธ์เดิมออกจากแบบจำลองและแทนที่ด้วยเลเยอร์ใหม่ ที่ออกแบบสำหรับงานจำแนกรอยโรคผิวหนังโดยเฉพาะ โดยเลเยอร์ใหม่ มีรายละเอียดดังนี้

- (1) Global Average Pooling 2D

ทำหน้าที่ลดมิติของ Feature Map ให้เป็นรูปเวกเตอร์ ซึ่งช่วยลดจำนวนพารามิเตอร์และทำให้แบบจำลองมีความทนทานต่อการเปลี่ยนตำแหน่งของลักษณะเด่น

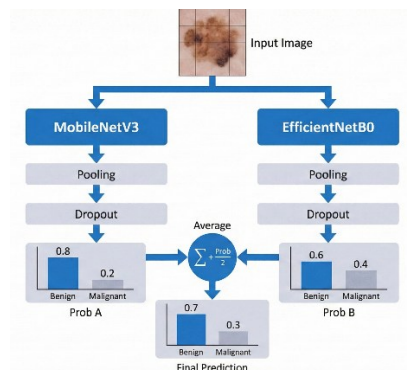
- (2) Dropout อัตราส่วน 0.3

เพื่อลดโอกาสเกิดการเรียนรู้เกิน (Overfitting) โดยสุ่มปิดการทำงานของบางนิวรอนระหว่างการฝึก

- (3) Dense Layer ที่ใช้ฟังก์ชัน Activation แบบ Softmax ทำหน้าที่คำนวณค่าความน่าจะเป็นของแต่ละกลุ่มและส่งผลลัพธ์การจำแนกรอยโรคในทั้ง 7 โรค

3.2.2 การรวมผลลัพธ์

ใช้วิธีการลงคะแนนแบบความน่าจะเป็น (Soft Voting) โดยนำเวกเตอร์ความน่าจะเป็นที่ได้จากการทำนายของทั้งสองแบบจำลองมาหาค่าเฉลี่ยเพื่อกำหนดผลลัพธ์สุดท้าย ซึ่งช่วยลดความแปรปรวน และเพิ่มความแม่นยำในการจำแนกโดยรวมได้อย่างมีนัยสำคัญ ดังแสดงในภาพที่ 5



ภาพ 5 สถาปัตยกรรมแบบจำลองแบบรวม

3.2.3 การตั้งค่าพารามิเตอร์การฝึกสอน

การฝึกสอนแบบจำลองดำเนินการบนสภาพแวดล้อม Google Colab โดยใช้หน่วยประมวลผลกราฟิก (GPU) NVIDIA Tesla T4 โดยมีรายละเอียดการกำหนดค่าและเทคนิคการฝึกสอน เพื่อให้ได้ประสิทธิภาพสูงสุด ดังนี้

(1) การตั้งค่าหลักและฟังก์ชัน

- ฟังก์ชันสูญเสีย เลือกใช้ Categorical Crossentropy ร่วมกับ Label Smoothing ที่ค่า 0.1 เพื่อลดความมั่นใจเกินเหตุของแบบจำลอง และเพิ่มความทั่วไปในการเรียนรู้
- ตัวปรับค่า ใช้ Adam Optimizer

(2) การฝึกสอน 2 ระยะ

- ระยะที่ 1 ฝึกสอนเฉพาะชั้นจำแนกผลลัพธ์ใหม่ ใช้เวลา 5 รอบ ด้วยอัตราการเรียนรู้ 1×10^{-3}
- ระยะที่ 2 ฝึกสอนทั้งแบบจำลองใช้เวลา 40 รอบ ด้วยอัตราการเรียนรู้ที่ลดลงเหลือ 1×10^{-5}

(3) เทคนิคช่วยฝึกสอน

- Early Stopping หยุดการฝึกสอนเมื่อค่าความสูญเสียในชุดข้อมูลตรวจสอบ ไม่ลดลงติดต่อกัน 6 รอบ
- ReduceLROnPlateau ลดอัตราการเรียนรู้ลงร้อยละ 20 (Factor 0.2) เมื่อค่าความสูญเสียไม่ดีขึ้นติดต่อกัน 3 รอบ
- Model Checkpoint บันทึกเฉพาะแบบจำลองที่มีค่าความถูกต้องสูงสุดบนชุดข้อมูลตรวจสอบเท่านั้น

3.3 การพัฒนาแอปพลิเคชัน

3.3.1 กรอบการพัฒนา

แอปพลิเคชันถูกพัฒนาขึ้นโดยใช้ Flutter ซึ่งเป็นกรอบการทำงานแบบข้ามแพลตฟอร์ม (Cross-platform Framework) ร่วมกับภาษา Dart การเลือกใช้เทคโนโลยีนี้ช่วยให้สามารถพัฒนาส่วนต่อประสานกับผู้ใช้ (User Interface: UI) ที่มีความสวยงาม ทันสมัย และตอบสนองการใช้งานได้อย่างรวดเร็วบนระบบปฏิบัติการ Android

3.3.2 โครงสร้างซอฟต์แวร์

สถาปัตยกรรมซอฟต์แวร์ถูกออกแบบโดยยึดหลักการแยกส่วนการทำงาน โดยแบ่งโครงสร้างออกเป็น 3 ส่วนหลัก เพื่อเพิ่มความยืดหยุ่นในการบำรุงรักษาและรองรับการขยายตัวของระบบในอนาคต ได้แก่

- (1) ส่วนแสดงผล
- (2) ส่วนจัดการตรรกะ
- (3) ส่วนจัดการข้อมูล

3.3.3 คุณสมบัติหลักของระบบ

ระบบถูกออกแบบให้มีคุณสมบัติที่ครอบคลุมกระบวนการวินิจฉัยและการจัดการข้อมูลอย่างครบถ้วน ดังนี้

- ระบบยืนยันตัวตน ประยุกต์ใช้บริการ Firebase Authentication เพื่อความปลอดภัยในการเข้าถึงข้อมูลส่วนบุคคลของผู้ใช้งาน
- การนำเข้าภาพถ่าย รองรับการนำเข้าภาพผ่านกล้องถ่ายรูปและคลังภาพภายในเครื่อง
- การประมวลผลออนไลน์ ใช้ TensorFlow Lite เพื่อทำการวินิจฉัยโรคจากภาพถ่ายได้ทันทีโดยไม่ต้องเชื่อมต่ออินเทอร์เน็ต
- ระบบบันทึกประวัติ จัดเก็บผลการวินิจฉัยและข้อมูลที่เกี่ยวข้องลงในฐานข้อมูล Cloud Firestore เพื่อให้ผู้ใช้สามารถดูย้อนหลังได้

4. ผลการทดลอง

4.1 ผลการประเมินประสิทธิภาพของแบบจำลอง

จากการทดสอบประสิทธิภาพของแบบจำลองโครงข่ายประสาทเทียมทั้ง 2 สถาปัตยกรรม ได้แก่ EfficientNetB0 และ MobileNetV3Small รวมถึงแบบจำลองแบบรวม ที่ใช้เทคนิคการลงคะแนนแบบความน่าจะเป็น จะเป็นการเพิ่มข้อมูลระหว่างการทดสอบบนชุดข้อมูลทดสอบ จำนวน 1,503 ภาพ ผลลัพธ์แสดงดังตารางที่ 4


ตาราง 4 เปรียบเทียบค่าประสิทธิภาพของแบบจำลอง

สถาปัตยกรรม	ความแม่นยำ	ความไว	คะแนน F1	ความถูกต้อง
MobileNetV3Small	82%	80%	80%	79.57%
EfficientNetB0	86%	84%	85%	84.03%
Ensemble	88%	86%	86%	85.70%

ผลการทดลองชี้ให้เห็นว่า แบบจำลองแบบรวมให้ค่าประสิทธิภาพสูงที่สุดในทุกตัวชี้วัด โดยมีค่าความถูกต้องอยู่ที่ร้อยละ 85.70 ซึ่งสูงกว่า MobileNetV3Small และ EfficientNetB0 อย่างมีนัยสำคัญ

4.1.1 การวิเคราะห์ความผิดพลาด

จากการวิเคราะห์ตารางความสับสน ในภาพที่ 6 พบว่า แบบจำลองสามารถจำแนกคลาส Melanocytic nevi (nv) ได้แม่นยำที่สุด (ทายถูก 904 จาก 1,006 ภาพ) เนื่องจากมีจำนวนข้อมูลฝึกสอนมากที่สุด ในขณะที่คลาส Melanoma (mel) มีการทำนายผิดพลาดปะปนกับคลาสอื่นเล็กน้อย โดยเฉพาะการทายผิดเป็น nv (69 ภาพ) และ bkl (14 ภาพ) เนื่องจากลักษณะทางคลินิกที่มีความคล้ายคลึงกันมากในระยะเริ่มต้น



ภาพ 6 ตารางความสับสนแสดงผลการจำแนกของแบบจำลองแบบรวมบนชุดข้อมูลทดสอบ

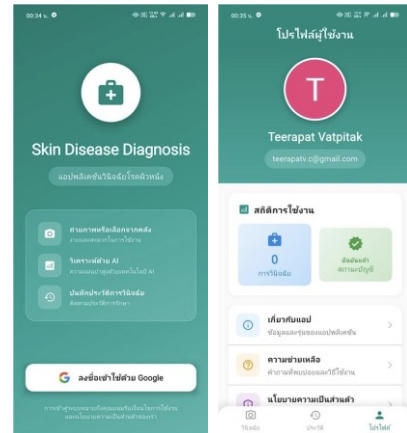
4.2 ผลการพัฒนาแอปพลิเคชัน

แอปพลิเคชันบนระบบปฏิบัติการ Android ถูกออกแบบและพัฒนาให้มีส่วนติดต่อผู้ใช้ที่ง่ายต่อการใช้งาน โดยรองรับการยืนยันตัวตนผ่านบัญชี Google เพื่อความปลอดภัยในการเข้าสู่ระบบ ดังแสดงในภาพที่ 7

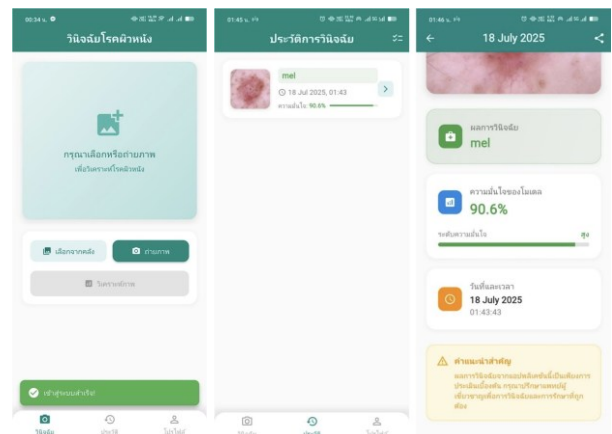
ผู้ใช้งานสามารถเริ่มวินิจฉัยโรคได้ทันทีด้วยการถ่ายภาพหรือเลือกรูปภาพจากคลังภาพ จากนั้นระบบจะประมวลผลและแสดงผลลัพธ์เป็นชื่อโรคที่มีความน่าจะเป็นสูงสุด และบันทึกประวัติการตรวจไว้ในระบบ ดังแสดงในภาพที่ 8

นอกจากนี้ แอปพลิเคชันยังมีฟังก์ชันเสริมในหน้าโปรไฟล์ ดังแสดงในภาพที่ 9 ซึ่งประกอบด้วยหน้าต่างข้อมูลช่วยเหลือเพื่อแนะนำขั้นตอนการใช้งานอย่างละเอียด และหน้านโยบาย

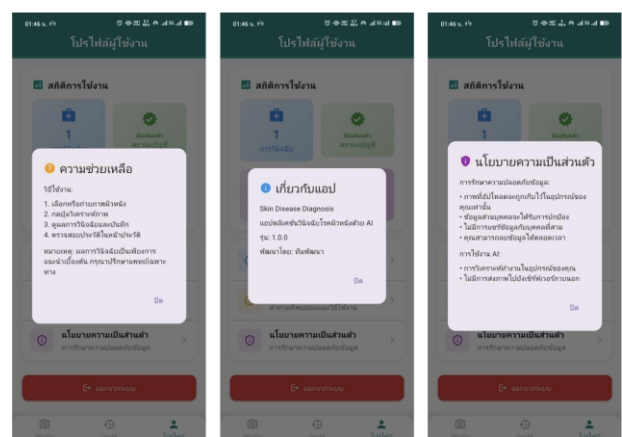
ความเป็นส่วนตัว เพื่อชี้แจงมาตรการรักษาความปลอดภัยของข้อมูลส่วนบุคคล เพื่อสร้างความเชื่อมั่นให้กับผู้ใช้งาน



ภาพ 7 หน้าเข้าสู่ระบบและหน้าโปรไฟล์



ภาพ 8 หน้าการวินิจฉัย แสดงผลลัพธ์และประวัติการตรวจ



ภาพ 9 หน้าต่างข้อมูลช่วยเหลือและนโยบายความเป็นส่วนตัว

5. สรุปและข้อเสนอแนะ

5.1 สรุปผลการดำเนินงาน

งานวิจัยนี้ประสบความสำเร็จในการพัฒนาแอปพลิเคชันบนสมาร์ทโฟนเพื่อคัดกรองโรคผิวหนัง 7 ประเภท โดยใช้การเรียนรู้แบบรวมระหว่าง EfficientNetB0 และ MobileNetV3Small ซึ่งแบบจำลองแบบรวมให้ค่าความถูกต้องสูงสุดที่ร้อยละ 85.70 ซึ่งสูงกว่า EfficientNetB0 (84.03%) และ MobileNetV3Small (79.57%) อย่างมีนัยสำคัญ นอกจากนี้ การลดขนาดไฟล์ของแบบจำลองลงร้อยละ 90 โดยแบบจำลอง EfficientNetB0 ลดลงเหลือ 4.69 MB และ MobileNetV3Small ลดลงเหลือ 1.16 MB รวมทั้งสิ้น 5.85 MB

5.2 ข้อเสนอแนะ

แม้แบบจำลองจะมีประสิทธิภาพสูงในภาพรวม แต่ยังพบข้อจำกัดเกี่ยวกับการจำแนกโรคที่มีลักษณะคล้ายคลึงกัน และความไม่สมดุลของจำนวนข้อมูล เพื่อให้งานวิจัยสมบูรณ์ยิ่งขึ้นจะต้องรวบรวมภาพถ่ายโรคผิวหนังเพิ่มเติมในกลุ่มที่มีข้อมูลน้อย อีกทั้งควรมีการทดสอบการใช้งานจริงร่วมกับแพทย์ผิวหนัง เพื่อประเมินประสิทธิภาพและผลกระทบ ก่อนนำไปใช้จริงในวงกว้าง

คำชี้แจงการใช้ AI

ต้นฉบับนี้มีเนื้อหาที่สร้างขึ้นหรือได้รับการสนับสนุนจากเครื่องมือปัญญาประดิษฐ์ (AI) ได้แก่ Gemini ซึ่งถูกนำมาใช้เพื่อช่วยในการปรับแก้ภาษา สรุปเนื้อหา จัดรูปแบบข้อความการสร้างภาพประกอบ การสรุปวรรณกรรม และการช่วยเขียนโค้ดเท่านั้น ทั้งนี้ ผู้เขียนได้ทบทวนและตรวจสอบเนื้อหาที่ได้รับการสนับสนุนจาก AI อย่างรอบคอบ เพื่อให้มั่นใจในความถูกต้อง ความเป็นต้นฉบับ และการปฏิบัติตามหลักจริยธรรมทางวิชาการ โดยเนื้อหาเชิงวิชาการ กระบวนการวิจัย การวิเคราะห์ผล และข้อสรุปทั้งหมดเป็นความรับผิดชอบของผู้เขียนแต่เพียงผู้เดียว

เอกสารอ้างอิง

- [1] H. A. Al-Shammari *et al.*, "The burden of skin and subcutaneous diseases: Findings from the global burden of disease study 2019," *Frontiers in Public Health*, vol. 11, p. 1145513, 2023.
- [2] M. V. Urban, R. J. Valiathan, and J. A. Pootrakul, "Global burden of skin disease representation in the literature: Bibliometric analysis," *Journal of Cutaneous Medicine and Surgery*, vol. 25, no. 6, pp. 612–620, 2021.
- [3] S. H. Al-Awaidy, "Prevalence of skin disease among the elderly in different clinical environments," *Oman Medical Journal*, vol. 31, no. 4, pp. 266–273, 2016.
- [4] M. H. M. El-Komy, S. A. E. A. Ghaffar, and D. A. E. R. E. Esawy, "Pattern of skin disorders in geriatrics," *Journal of Current Medical Research and Practice*, vol. 5, no. 1, pp. 58–63, 2020.
- [5] H. Feng, P. M. Berk-Krauss, P. Feng, and J. A. Stein, "Comparison of dermatologist density between urban and rural counties in the United States," *JAMA Dermatology*, vol. 154, no. 11, pp. 1265–1271, 2018.
- [6] P. Choonhakarn *et al.*, "Dermatological primary health care services for older adults in Thailand," *Journal of Health Research*, vol. 38, no. 1, 2024.
- [7] AIM at Melanoma Foundation, "Early detection of melanoma," *Melanoma 101*. [Online]. Available: <https://www.aimatmelanoma.org/melanoma-101/early-detection-of-melanoma/>. [Accessed: 30-Nov-2024].
- [8] A. J. Stratigos *et al.*, "Improving outcomes in patients with melanoma: Strategies to ensure an early diagnosis," *Melanoma Management*, vol. 2, no. 3, pp. 247–257, 2015.
- [9] G. Litjens *et al.*, "A survey on deep learning in medical image analysis," *Medical Image Analysis*, vol. 42, pp. 60–88, 2017.
- [10] M. A. Kassem, M. Hosny, and M. M. Fouad, "Lightweight CNN towards skin lesions automated diagnosis in dermoscopic images," in *2023 International Conference on Digital Age & Technological Advances for Sustainable Development (ICDATA)*, 2023, pp. 1–6.

- [11] A. Howard *et al.*, "Searching for MobileNetV3," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2019, pp. 1314–1324.
- [12] M. Tan and Q. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019, pp. 6105–6114.
- [13] United Nations, "Goal 3: Ensure healthy lives and promote well-being for all at all ages," *Sustainable Development Goals*. [Online]. Available: <https://sdgs.un.org/goals/goal3>. [Accessed: 30-Nov-2024].
- [14] P. Tschandl, C. Rosendahl, and H. Kittler, "The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions," *Scientific Data*, vol. 5, no. 1, Art. no. 180161, 2018.
- [15] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [16] A. H. Shahin, A. Kamal, and M. A. El-Hag, "Deep learning analysis using ResNet and InceptionV3 for skin lesion classification," in *2019 IEEE International Conference on Imaging Systems and Techniques (IST)*, Abu Dhabi, UAE, 2019, pp. 1–6.
- [17] Y. Zhang, H. Wang, and Y. Phillips, "Skin cancer detection using DenseNet and transfer learning," in *2020 International Joint Conference on Neural Networks (IJCNN)*, Glasgow, UK, 2020, pp. 1–7.
- [18] S. S. Chaturvedi, J. V. Tembhurne, and T. Diwan, "A multi-class skin cancer classification using deep convolutional neural networks," *Multimedia Tools and Applications*, vol. 79, no. 39, pp. 28477–28498, 2020.
- [19] M. Z. Atwany, A. H. Majid, and X. Sybing, "EfficientNet-B0 based skin lesion classification using transfer learning," in *2022 IEEE 12th International Conference on System Engineering and Technology (ICSET)*, Bandung, Indonesia, 2022, pp. 156–161.
- [20] B. Harangi, "Skin lesion classification with ensembles of deep convolutional neural networks," *Journal of Biomedical Informatics*, vol. 86, pp. 25–32, 2018.
- [21] A. Mahbod *et al.*, "Fusing fine-tuned deep features for skin lesion classification," *Computerized Medical Imaging and Graphics*, vol. 71, pp. 19–29, 2019.